



รายงาน

Project 1

เสนอ

ดร.สุภาพร เอื้อจงมานี

จัดทำโดย

นายภคิน สีญารัชคุณ

รหัสนิต 6610502188

รายงานนี้เป็นส่วนหนึ่งของวิชา

Statistics in Computer Engineering Applications

ภาควิชาวิศวกรรมคอมพิวเตอร์

มหาวิทยาลัยเกษตรศาสตร์

ภาคเรียนที่ 2 ปีการศึกษา 2568

สารบัญ

สารบัญ.....	1
Part 1.0: EDA.....	2
Part 1.1: Modeling1	2
1) Data Science Workflow	2
Workflow 1:	3
Workflow 2:	5
Workflow 3	7
2) Result interpretation	9
Part 1.2: Feature Extraction.....	11
Linear Discriminant Analysis (LDA)	11
Principal Component Analysis (PCA).....	11
Part 2.0: EDA.....	12
Part 2.1: Clustering	13
Part 2.2: Modeling2	14
1) Data Science Workflow	14
Workflow 1:	14
Workflow 2:	17
2) Result interpretation	18
Part 2.3: Visualization	19

Part 1.0: EDA

ในการเตรียมข้อมูลสำหรับการวิเคราะห์ ได้เริ่มจากการรวมชุดข้อมูลทั้งสองชุดเข้าด้วยกันเป็นชุดข้อมูลเดียว จากนั้นได้ตรวจสอบโครงสร้างและขนาดของชุดข้อมูลเพื่อให้แน่ใจว่าการรวมข้อมูลเป็นไปอย่างถูกต้อง ต่อมาได้ทำการตรวจสอบตัวแปรแต่ละตัวและจำแนกชนิดของตัวแปรออกเป็นตัวแปรเชิงตัวเลขและตัวแปรเชิงกลุ่ม

หลังจากนั้นได้ทำการตรวจสอบค่าที่หายไปในแต่ละตัวแปร โดยในขั้นตอนการสำรวจข้อมูลเบื้องต้น (Exploratory Data Analysis: EDA) ได้กำหนดเกณฑ์ในการจัดการข้อมูลที่หายไป กล่าวคือ หากตัวแปรใดมีสัดส่วนของข้อมูลที่หายไปมากกว่าร้อยละ 40 จะทำการตัดตัวแปรนั้นออกจากการวิเคราะห์ เนื่องจากตัวแปรที่มีข้อมูลหายไปในสัดส่วนสูงอาจทำให้ข้อมูลที่เหลือไม่เพียงพอในการสะท้อนลักษณะจริงของตัวแปร และการเติมค่าทดแทนในปริมาณมากอาจก่อให้เกิดอคติ (bias) และลดความน่าเชื่อถือของผลการวิเคราะห์ ในขณะที่ตัวแปรที่มีข้อมูลหายไปไม่เกินเกณฑ์ดังกล่าวจะทำการเติมค่าแทน โดยตัวแปรเชิงตัวเลขใช้ค่ามัธยฐาน (median) และตัวแปรเชิงกลุ่มใช้ค่าฐานนิยม (mode)

ภายหลังการจัดการค่าที่หายไป ได้ทำการสำรวจการกระจายของข้อมูลในแต่ละตัวแปร โดยตัวแปรเชิงตัวเลขถูกวิเคราะห์ด้วยกราฟฮิสโตแกรมและบ็อกซ์พล็อต รวมถึงการพิจารณาค่าความเบ้ (skewness) และความโด่ง (kurtosis) เพื่อประเมินลักษณะการกระจายของข้อมูล ขณะที่ตัวแปรเชิงกลุ่มถูกวิเคราะห์ด้วยกราฟแท่งและการพิจารณาสัดส่วนของข้อมูลในแต่ละกลุ่ม

จากนั้นได้คำนวณค่าสถิติเชิงพรรณนาเพื่อสรุปลักษณะพื้นฐานของข้อมูล เนื่องจากชุดข้อมูลมีจำนวนตัวแปรค่อนข้างมาก การวิเคราะห์ความสัมพันธ์จึงมุ่งเน้นไปที่ความสัมพันธ์ระหว่างตัวแปรอิสระกับตัวแปรเป้าหมาย สำหรับตัวแปรเชิงตัวเลข ได้ใช้การเปรียบเทียบการกระจายของข้อมูลในแต่ละคลาสของตัวแปรเป้าหมายด้วยบ็อกซ์พล็อตและการทดสอบทางสถิติแบบไม่อาศัยสมมติฐานการแจกแจงปกติ ส่วนตัวแปรเชิงกลุ่ม ได้ใช้การทดสอบไคสแควร์ (Chi-square test) ร่วมกับการคำนวณขนาดอิทธิพล เช่น Cramér's V และ Theil's U เพื่อประเมินระดับความสัมพันธ์ระหว่างตัวแปร

Part 1.1: Modeling1

1) Data Science Workflow

Workflow 1:

ขั้นตอนการเตรียมข้อมูลถูกออกแบบมาเพื่อเพิ่มความน่าเชื่อถือและประสิทธิภาพของโมเดลในการทำนายผลลัพธ์ เริ่มจากการแยกตัวแปรอิสระและตัวแปรเป้าหมาย และตัดแถวข้อมูลที่มีค่าตัวแปรเป้าหมายหายไปออกจากชุดข้อมูล เนื่องจากโมเดลแบบ supervised learning จำเป็นต้องมีค่าจริงของตัวแปรเป้าหมายในการฝึกและประเมินผล อีกทั้งการเติมค่าตัวแปรเป้าหมายอาจก่อให้เกิดอคติและทำให้ผลลัพธ์ขาดความน่าเชื่อถือ

จากนั้นได้แบ่งข้อมูลออกเป็นชุดฝึกและชุดทดสอบด้วยวิธี stratified sampling เพื่อรักษาสัดส่วนของคลาสตัวแปรเป้าหมายให้ใกล้เคียงกัน วิธีการนี้ช่วยลดความเอนเอียงของการประเมินโมเดล โดยเฉพาะในกรณีที่ข้อมูลมีความไม่สมดุลระหว่างคลาส ทำให้ผลการทดสอบสะท้อนประสิทธิภาพของโมเดลกับข้อมูลจริงได้ดียิ่งขึ้น

Preprocessing:

ในการจัดการค่าที่หายไป ได้เลือกใช้ค่ามัธยฐานสำหรับตัวแปรเชิงตัวเลขและค่าฐานนิยมสำหรับตัวแปรเชิงกลุ่ม โดยคำนวณค่าสถิติจากชุดฝึกเท่านั้นและนำไปใช้กับชุดทดสอบ วิธีการนี้ช่วยป้องกันปัญหาข้อมูลรั่วไหล (data leakage) และเพิ่มความสามารถในการนำโมเดลไปใช้งานกับข้อมูลใหม่ได้อย่างมีประสิทธิภาพ

นอกจากนี้ ได้ใช้การแปลงข้อมูลแบบ Yeo–Johnson เพื่อจัดการกับตัวแปรที่มีความเบ้ เนื่องจากวิธีดังกล่าวสามารถรองรับข้อมูลที่มีค่าเป็นศูนย์หรือค่าลบได้ การลดความเบ้ของข้อมูลช่วยลดอิทธิพลของค่าผิดปกติ ทำให้กระบวนการเรียนรู้ของโมเดลมีความเสถียรและช่วยปรับปรุงประสิทธิภาพในการทำนาย

สุดท้าย การใช้ One-Hot Encoding ในการแปลงตัวแปรเชิงหมวดหมู่ช่วยหลีกเลี่ยงการสร้างลำดับเชิงอันดับเทียมระหว่างหมวดหมู่ ทำให้โมเดลสามารถเรียนรู้ความสัมพันธ์ของข้อมูลเชิงหมวดหมู่กับตัวแปรเป้าหมายได้อย่างถูกต้อง ส่งผลให้ประสิทธิภาพของโมเดลโดยรวมดีขึ้น

Feature Selection:

การคัดเลือกชุดตัวแปรถูกออกแบบมาเพื่อลดความซับซ้อนของโมเดล เพิ่มเสถียรภาพในการเรียนรู้ และปรับปรุงประสิทธิภาพในการทำนายผลลัพธ์ โดยเริ่มจากการใช้เทคนิคการคัดกรองตัวแปรเชิงสถิติ (filter-based methods) ซึ่งไม่ขึ้นกับโมเดลและสามารถลดความซับซ้อนของข้อมูลได้อย่างมีประสิทธิภาพ

ขั้นแรก ได้ใช้เทคนิค Low Variance Filtering เพื่อคัดกรองตัวแปรที่ไม่มีความแปรปรวนออกจากชุดข้อมูล โดยกำหนดค่า threshold เท่ากับ 0 เพื่อกำจัดตัวแปรที่มีค่าเหมือนกันในทุกตัวอย่าง (constant features) เนื่องจาก

ตัวแปรลักษณะดังกล่าวไม่สามารถช่วยในการจำแนกหรือทำนายตัวแปรเป้าหมายได้ การตัดตัวแปรเหล่านี้ออกช่วยลดจำนวนมิติของข้อมูลโดยไม่กระทบต่อประสิทธิภาพของโมเดล

จากนั้น ได้ใช้เทคนิค High Correlation Filtering เพื่อลดความซ้ำซ้อนระหว่างตัวแปรเชิงตัวเลข โดยกำหนดเกณฑ์ค่าสหสัมพันธ์ที่สูงกว่า 0.8 และเลือกตัดตัวแปรที่มีความสัมพันธ์กับตัวแปรเป้าหมายน้อยกว่าออกก่อน วิธีการนี้ช่วยลดปัญหา multicollinearity ซึ่งมีผลโดยตรงต่อความเสถียรของค่าสัมประสิทธิ์ในโมเดล Logistic Regression และช่วยให้โมเดลสามารถตีความผลลัพธ์ได้ชัดเจนยิ่งขึ้น

ภายหลังขั้นตอนดังกล่าว ยังคงเหลือตัวแปรจำนวนประมาณ 100 ตัว ซึ่งถือว่ามีความค่อนข้างมาก จึงได้ใช้เทคนิค Recursive Feature Elimination (RFE) เพื่อคัดเลือกชุดตัวแปรที่เหมาะสมที่สุด โดยพิจารณาจากจำนวนตัวแปรที่ให้ค่า F1-score สูงสุด การลดจำนวนตัวแปรด้วย RFE ช่วยลดความซับซ้อนของโมเดล ลดความเสี่ยงของ overfitting และเพิ่มประสิทธิภาพในการทำนาย ทำให้โมเดลสามารถ generalize กับข้อมูลใหม่ได้ดียิ่งขึ้น

Modeling:

ในขั้นตอนการสร้างแบบจำลอง (Modeling) ได้เลือกใช้ Logistic Regression เป็นแบบจำลองหลัก เนื่องจากเป็น workflow แรกของการวิเคราะห์ จึงต้องการแบบจำลองพื้นฐาน (baseline model) ที่มีความเรียบง่าย มีเสถียรภาพ และสามารถตีความผลลัพธ์ได้ง่าย Logistic Regression เป็นโมเดลที่เหมาะสมสำหรับปัญหาการจำแนกประเภท (classification) และช่วยให้สามารถเข้าใจความสัมพันธ์ระหว่างตัวแปรอิสระกับตัวแปรเป้าหมายผ่านค่าสัมประสิทธิ์ของโมเดลได้อย่างชัดเจน

ก่อนทำการฝึกโมเดล ได้ดำเนินการ ปรับขนาดข้อมูล (Feature Scaling) สำหรับตัวแปรเชิงตัวเลข เนื่องจาก Logistic Regression เป็นโมเดลที่มีความไวต่อสเกลของข้อมูล หากตัวแปรแต่ละตัวมีช่วงค่าที่แตกต่างกันมาก อาจทำให้ค่าสัมประสิทธิ์ของโมเดลถูกครอบงำโดยตัวแปรที่มีค่าสูง ส่งผลให้ประสิทธิภาพของโมเดลลดลง การทำ feature scaling จึงช่วยให้โมเดลเรียนรู้ข้อมูลได้อย่างสมดุลและเพิ่มเสถียรภาพในการฝึกโมเดล

สำหรับการตั้งค่าพารามิเตอร์ของ Logistic Regression ได้กำหนดค่า $C = 1.0$ ซึ่งเป็นค่ามาตรฐานที่ช่วยควบคุมความแรงของการทำ L2 regularization โดยค่า C เป็นค่าผกผันกับความแรงของ regularization การเลือกค่า C ที่ไม่เล็กหรือใหญ่จนเกินไปช่วยสร้างสมดุลระหว่างความซับซ้อนของโมเดลและความสามารถในการอธิบายข้อมูล ส่งผลให้สามารถลดปัญหา overfitting ได้โดยไม่ทำให้โมเดลมีข้อจำกัดมากเกินไป

นอกจากนี้ ได้กำหนดค่า `max_iter = 3000` เพื่อให้กระบวนการเรียนรู้ของโมเดลสามารถลู่เข้า (converge) ได้อย่างสมบูรณ์ และตั้งค่า `random_state = 0` เพื่อให้ผลลัพธ์ของการทดลองสามารถทำซ้ำได้ (reproducibility)

สุดท้าย ได้ผสมผลลัพธ์จากขั้นตอน Feature Selection (Low Variance Filtering, High Correlation Filtering และ RFE) โดยเลือกชุดตัวแปรที่ให้ค่า F1-score สูงที่สุด มาใช้ในการฝึกโมเดลขั้นสุดท้าย การผสมผสานระหว่างการลดจำนวนตัวแปร การปรับขนาดข้อมูล และการใช้ Logistic Regression ที่มี regularization ช่วยลดความซับซ้อนของโมเดล เพิ่มประสิทธิภาพในการทำนาย และทำให้โมเดลมีความสามารถในการทั่วไปกับข้อมูลใหม่ได้ดีขึ้น

Performance evaluation:

ผลการประเมิน Workflow 1 ซึ่งใช้ Logistic Regression และคัดเลือกตัวแปรจำนวน 10 features แสดงให้เห็นว่าโมเดลมีประสิทธิภาพในระดับค่อนข้างต่ำ โดยมีค่า Accuracy = 0.30 และ Macro F1-score = 0.25 สะท้อนว่าโมเดลยังไม่สามารถจำแนกข้อมูลในแต่ละคลาสได้อย่างมีประสิทธิภาพ

เมื่อพิจารณารายคลาส พบว่าโมเดลสามารถทำนายคลาส 1 และคลาส 2 ได้ดีกว่าคลาสอื่น ขณะที่คลาส 4 ไม่สามารถทำนายได้เลย (Recall = 0.00) ซึ่งบ่งชี้ถึงข้อจำกัดของโมเดลเชิงเส้นในการจับความสัมพันธ์ที่ซับซ้อน รวมถึงผลกระทบจากข้อมูลที่ไม่สมดุล

โดยสรุป แม้การลดจำนวนตัวแปรเหลือ 10 features จะช่วยลดความซับซ้อนของโมเดล แต่ยังไม่เพียงพอที่จะปรับปรุงประสิทธิภาพโดยรวม ทำให้ Workflow 1 เหมาะสมในฐานะ baseline model สำหรับใช้เปรียบเทียบกับ Workflow 2

Workflow 2:

ใน Workflow 2 ได้แบ่งข้อมูลออกเป็นชุดฝึก (training set) และชุดทดสอบ (test set) โดยใช้วิธีเดียวกันกับ Workflow 1 เพื่อให้สามารถเปรียบเทียบประสิทธิภาพของโมเดลระหว่างสอง workflow ได้อย่างยุติธรรม

Preprocessing:

ขั้นตอนการเตรียมข้อมูล (Preprocessing) ดำเนินการในลักษณะเดียวกับ Workflow 1 ไม่ว่าจะเป็นการจัดการ

ค่าที่หายไป การเข้ารหัสตัวแปรเชิงหมวดหมู่ และการปรับขนาดข้อมูลสำหรับตัวแปรที่จำเป็น อย่างไรก็ตาม Workflow 2 จะไม่รวมขั้นตอนการจัดการข้อมูลที่มีการกระจายแบบเบ้ (skewness handling) เนื่องจากแบบจำลองที่ใช้ใน workflow นี้สามารถรองรับการกระจายของข้อมูลที่ไม่เป็นปกติได้ดีกว่า

Feature Selection:

กระบวนการคัดเลือกตัวแปร (Feature Selection) ยังคงอิงแนวคิดเดียวกับ Workflow 1 โดยเริ่มจากการใช้ Low Variance Filtering เพื่อกำจัดตัวแปรที่ไม่มีความแปรปรวนออกจากชุดข้อมูล

สำหรับขั้นตอน High Correlation Filtering ได้ปรับค่า threshold ของค่าสหสัมพันธ์เป็น 0.9 แทน 0.8 เนื่องจากแบบจำลอง Random Forest มีความทนทานต่อปัญหา multicollinearity มากกว่าโมเดลเชิงเส้น จึงไม่จำเป็นต้องตัดตัวแปรที่มีความสัมพันธ์กันในระดับที่ต่ำกว่านี้ออกมากนัก การตั้งค่า threshold ที่สูงขึ้นช่วยรักษาข้อมูลเชิงโครงสร้างที่อาจเป็นประโยชน์ต่อโมเดลไว้ได้

ใน Workflow นี้ ไม่ได้ใช้เทคนิค Recursive Feature Elimination (RFE) แต่เลือกใช้คุณสมบัติของ Random Forest ในการประเมิน Feature Importance แทน โดยจะทำการเรียงลำดับตัวแปรตามค่าความสำคัญ และทดลองเลือกจำนวนตัวแปรที่แตกต่างกัน จากนั้นประเมินประสิทธิภาพของโมเดลด้วยค่า F1-score เพื่อระบุจำนวนตัวแปรที่ให้ผลลัพธ์ที่ดีที่สุด ชุดตัวแปรที่ทำให้ค่า F1-score สูงที่สุดจะถูกนำมาใช้ในการฝึกโมเดลขั้นสุดท้าย

Modeling:

ใน Workflow 2 ได้เลือกใช้ Random Forest Classifier เป็นแบบจำลองหลัก เนื่องจากเป็นโมเดลแบบ ensemble ที่สามารถเรียนรู้ความสัมพันธ์เชิงไม่เชิงเส้น (non-linear relationships) และปฏิสัมพันธ์ระหว่างตัวแปรได้ดีกว่าโมเดลเชิงเส้นอย่าง Logistic Regression ที่ใช้ใน Workflow 1 ซึ่งจากผลการทดลองใน Workflow 1 พบว่าโมเดลยังมีข้อจำกัดในการจำแนกคลาสที่มีลักษณะซับซ้อนและไม่สมดุลกัน

Random Forest ทำงานโดยการรวมผลการทำนายจากต้นไม้ตัดสินใจจำนวนมาก (decision trees) ซึ่งช่วยลดปัญหา overfitting และเพิ่มความเสถียรของโมเดลเมื่อเทียบกับการใช้ต้นไม้เดี่ยว นอกจากนี้ โมเดลยังสามารถจัดการกับความสัมพันธ์ระหว่างตัวแปรที่มีความซ้ำซ้อน (multicollinearity) ได้ดี จึงเหมาะสมกับชุดข้อมูลที่มีจำนวนตัวแปรค่อนข้างมาก

ในการตั้งค่าพารามิเตอร์ ได้กำหนดค่า `n_estimators = 500` เพื่อให้มีจำนวนต้นไม้เพียงพอสำหรับการเรียนรู้รูปแบบของข้อมูลอย่างครอบคลุม และกำหนด `random_state = 0` เพื่อให้ผลลัพธ์สามารถทำซ้ำได้ (reproducibility) นอกจากนี้ ได้ใช้ `class_weight = "balanced"` เพื่อปรับน้ำหนักของแต่ละคลาสให้เหมาะสมกับข้อมูลที่มีการกระจายของคลาสไม่สมดุล ซึ่งช่วยให้โมเดลให้ความสำคัญกับคลาสที่มีจำนวนตัวอย่างน้อยมากขึ้น และช่วยปรับปรุงค่า F1-score โดยเฉพาะในระดับ macro-average

Performance evaluation:

ผลการประเมิน Workflow 2 ซึ่งใช้ Random Forest Classifier และคัดเลือกตัวแปรจำนวน 40 features แสดงให้เห็นว่าโมเดลมีประสิทธิภาพดีขึ้นอย่างชัดเจนเมื่อเทียบกับ Workflow 1 โดยมีค่า Accuracy = 0.41 และ Macro F1-score = 0.32

เมื่อพิจารณารายคลาส พบว่าโมเดลสามารถทำนายคลาส 2, 3 และ 5 ได้ดีขึ้น โดยเฉพาะคลาส 2 และคลาส 5 ซึ่งมีค่า Recall และ F1-score ค่อนข้างสูง แสดงให้เห็นว่า Random Forest สามารถเรียนรู้ความสัมพันธ์เชิงไม่เชิงเส้นของข้อมูลได้ดีกว่า Logistic Regression อย่างไรก็ตาม โมเดลยังไม่สามารถทำนายคลาส 4 ได้ (Recall = 0.00) ซึ่งสะท้อนถึงข้อจำกัดจากจำนวนข้อมูลที่มีอยู่อย่างจำกัดและปัญหาคลาสไม่สมดุล

โดยสรุป การใช้ Random Forest ร่วมกับการคัดเลือกตัวแปรจำนวนเหมาะสมช่วยปรับปรุงประสิทธิภาพของโมเดลได้อย่างชัดเจน โดย Workflow 2 ให้ผลลัพธ์เหนือกว่า baseline ใน Workflow 1 ทั้งในด้าน Accuracy และ Macro F1-score

Workflow 3

ใน Workflow 3 ได้ทำการแบ่งข้อมูลออกเป็นชุดฝึก (training set) และชุดทดสอบ (test set) โดยใช้วิธีเดียวกับ Workflow 1 และ Workflow 2 เพื่อให้การเปรียบเทียบประสิทธิภาพของโมเดลระหว่างแต่ละ workflow เป็นไปอย่างยุติธรรมและอยู่บนเงื่อนไขเดียวกัน

Preprocessing:

ขั้นตอนการเตรียมข้อมูลใช้แนวทางเดียวกับ Workflow 2 โดยไม่ทำการจัดการความเบ้ของข้อมูล (skewness

handling) เนื่องจากโมเดลที่ใช้ใน Workflow นี้ไม่จำเป็นต้องอาศัยสมมติฐานการกระจายของข้อมูล และสามารถจัดการกับข้อมูลที่มีการกระจายไม่เป็นปกติได้โดยตรง

Feature Selection:

ขั้นตอนการคัดเลือกตัวแปรใช้วิธีเดียวกับ Workflow 2 โดยไม่มีการเปลี่ยนแปลง เพื่อควบคุมตัวแปรด้าน preprocessing และ feature selection ให้คงที่ และมุ่งเน้นการเปรียบเทียบผลกระทบจากการเลือกแบบจำลอง (modeling choice) ต่อประสิทธิภาพของโมเดลเป็นหลัก

Modeling:

ใน Workflow 3 ได้เลือกใช้ Extreme Gradient Boosting (XGBoost) ซึ่งเป็นโมเดลแบบ boosting ที่มีประสิทธิภาพสูงในการจัดการข้อมูลเชิงตาราง (tabular data) และสามารถเรียนรู้ความสัมพันธ์เชิงไม่เชิงเส้นที่ซับซ้อนได้ดีกว่าโมเดลใน Workflow ก่อนหน้า XGBoost ทำงานโดยการสร้างต้นไม้ตัดสินใจแบบลำดับ (sequential trees) เพื่อแก้ไขข้อผิดพลาดจากรอบก่อนหน้า ส่งผลให้โมเดลมีความแม่นยำและความสามารถในการจำแนกสูงขึ้น

การตั้งค่า `learning_rate = 0.05` ร่วมกับ `n_estimators = 1000` ช่วยให้โมเดลเรียนรู้ข้อมูลอย่างค่อยเป็นค่อยไป ลดความเสี่ยงของ overfitting ขณะที่พารามิเตอร์ `max_depth = 5`, `subsample = 0.9` และ `colsample_bytree = 0.9` ช่วยควบคุมความซับซ้อนของโมเดลและเพิ่มความสามารถในการ generalize กับข้อมูลใหม่ นอกจากนี้ การใช้ objective แบบ `multi:softprob` ทำให้โมเดลเหมาะสมกับปัญหาการจำแนกหลายคลาส และสามารถประเมินผลด้วยตัวชี้วัดที่เหมาะสมได้โดยตรง

โดยสรุป การผสาน XGBoost เข้ากับขั้นตอน preprocessing และ feature selection ที่เหมือนกับ Workflow 2 ช่วยให้การเปรียบเทียบผลลัพธ์มุ่งเน้นไปที่ประสิทธิภาพของโมเดลเป็นหลัก และคาดว่าจะช่วยปรับปรุงค่า F1-score และความสามารถในการจำแนกข้อมูลได้ดียิ่งขึ้น

Performance evaluation:

ผลการประเมิน Workflow 3 ซึ่งใช้ XGBoost Classifier แสดงให้เห็นว่าโมเดลมีประสิทธิภาพดีที่สุดเมื่อเทียบกับ Workflow ก่อนหน้า โดยมีค่า `Accuracy = 0.43` และ `Macro F1-score = 0.42` สะท้อนถึงความสามารถที่ดีขึ้นในการจำแนกข้อมูลหลายคลาส

เมื่อพิจารณารายคลาส พบว่าโมเดลสามารถทำนายคลาส 1 และคลาส 3 ได้ดี โดยมีค่า Recall สูง ขณะที่คลาสอื่นยังมีความผันผวนอยู่บ้าง ซึ่งสะท้อนถึงผลกระทบจากจำนวนข้อมูลที่จำกัดและความไม่สมดุลของคลาส อย่างไรก็ตาม ค่า Macro-average F1-score ที่สูงขึ้นบ่งชี้ว่า XGBoost สามารถจัดการกับความสัมพันธ์ที่ซับซ้อนของข้อมูลได้ดีกว่า Logistic Regression และ Random Forest

โดยสรุป Workflow 3 ให้ผลลัพธ์ที่เหนือกว่าในภาพรวม แสดงให้เห็นว่าการใช้โมเดล boosting ร่วมกับขั้นตอน preprocessing และ feature selection เดียวกัน สามารถช่วยปรับปรุงประสิทธิภาพของโมเดลได้อย่างมีนัยสำคัญ

2) Result interpretation

a) แบบจำลองขั้นสุดท้ายจาก Workflow 3 (XGBoost Classifier) ให้ผลการประเมินดังนี้: Accuracy (macro) = 0.43, F1-score (macro) = 0.42 และจาก Confusion Matrix พบว่าโมเดลสามารถทำนายบางคลาสได้ดี (เช่น คลาส 1 และ 3) แต่ยังคงมีความสับสนระหว่างคลาสที่มีลักษณะใกล้เคียงกัน โดยเฉพาะคลาสที่มีจำนวนข้อมูลน้อย

โดยรวมแล้ว ประสิทธิภาพของโมเดลอยู่ในระดับ ปานกลาง ยังไม่ถือว่าดีมาก เนื่องจากค่า Accuracy และ F1-score ยังต่ำกว่า 0.5 อย่างไรก็ตาม เมื่อพิจารณาข้อจำกัดของข้อมูล เช่น ขนาดข้อมูลที่จำกัด จำนวนคลาสที่มาก และปัญหาคลาสไม่สมดุล ผลลัพธ์ดังกล่าวถือว่าน่าพอใจและแสดงให้เห็นถึงการปรับปรุงที่ชัดเจนจาก workflow ก่อนหน้า

b) จากการวิเคราะห์ความสำคัญของตัวแปรด้วยวิธี Permutation Importance และการพิจารณา SHAP ในภาพรวม พบว่าโมเดลได้รับอิทธิพลหลักจากตัวแปรด้านเศรษฐกิจ โครงสร้างแรงงาน ทรัพยากรธรรมชาติ และคุณภาพชีวิต มากกว่าการแบ่งตามภูมิภาคเพียงอย่างเดียว

ตัวแปรที่มีความสำคัญสูง ได้แก่ ดัชนีการผลิตอาหาร พื้นที่ป่า (ตารางกิโลเมตร) สัดส่วนแรงงานหญิงที่มีความเปราะบาง อายุคาดเฉลี่ยของเพศหญิง และอัตราส่วนระดับราคาตามค่า PPP ซึ่งสะท้อนว่าโมเดลใช้ข้อมูลที่เกี่ยวข้องกับระดับการพัฒนาเศรษฐกิจ ความมั่นคงด้านอาหาร และสภาพความเป็นอยู่ของประชากรในการทำนายผลลัพธ์เป็นหลัก

ในขณะที่ตัวแปรด้านภูมิภาควิเคราะห์มีความสำคัญในระดับรอง แสดงให้เห็นว่าโมเดลสามารถเรียนรู้ความสัมพันธ์เชิงโครงสร้างของประเทศได้ดีกว่าการพึ่งพาการจัดกลุ่มเชิงภูมิศาสตร์เพียงอย่างเดียว โดยภาพรวมโมเดลมีการพิจารณาปัจจัยหลายด้านร่วมกัน ไม่ได้ขึ้นอยู่กับตัวแปรใดตัวแปรหนึ่งเป็นหลัก

Gender Ratio Class 1:

โมเดลได้รับอิทธิพลหลักจาก สัดส่วนแรงงานหญิงที่มีความเปราะบาง และ จำนวน Secure Internet servers แสดงให้เห็นว่ากลุ่มนี้มีความสัมพันธ์กับโครงสร้างแรงงานหญิงและระดับโครงสร้างพื้นฐานทางดิจิทัล ขณะที่ตัวแปรด้านพื้นที่และทรัพยากรธรรมชาติมีผลต่อโมเดลค่อนข้างน้อย

Gender Ratio Class 2:

ตัวแปรที่สำคัญที่สุดคือ ระดับราคาตามค่า PPP, Secure Internet servers และ หนี้ต่างประเทศต่อ GNI สะท้อนว่ากลุ่มนี้เชื่อมโยงกับเสถียรภาพทางเศรษฐกิจ ภาระหนี้ และระดับการพัฒนาโครงสร้างพื้นฐาน โดยปัจจัยด้านคุณภาพชีวิต เช่น อายุคาดเฉลี่ยของเพศหญิง มีบทบาทรอง

Gender Ratio Class 3:

โมเดลให้ความสำคัญกับ พื้นที่ป่า (ทั้งสัดส่วนและขนาด) เป็นหลัก ร่วมกับ โครงสร้างพื้นฐานทางดิจิทัล และ ระดับราคา PPP แสดงว่ากลุ่มนี้มีลักษณะเด่นด้านทรัพยากรธรรมชาติและระดับการพัฒนาเชิงโครงสร้าง มากกว่าปัจจัยด้านแรงงานหรือภูมิภาค

Gender Ratio Class 4:

ตัวแปรที่มีอิทธิพลสูงสุดคือ สัดส่วนพื้นที่ป่า และ ดัชนีการผลิตอาหาร สะท้อนถึงประเทศที่มีความสัมพันธ์ระหว่าง Gender Ratio กับความมั่นคงด้านทรัพยากรและการผลิตอาหาร ปัจจัยทางเศรษฐกิจมหภาคและภูมิภาควิเคราะห์มีผลต่อโมเดลในระดับรอง

Gender Ratio Class 5:

โมเดลได้รับอิทธิพลจาก ขนาดพื้นที่ประเทศ, พื้นที่ป่า และ ระดับราคา PPP เป็นหลัก แสดงให้เห็นว่ากลุ่มนี้มี Gender Ratio ที่สัมพันธ์กับลักษณะเชิงกายภาพของประเทศและโครงสร้างเศรษฐกิจโดยรวม มากกว่าปัจจัยด้านแรงงานหญิงหรือโครงสร้างพื้นฐานดิจิทัล

c) ผลการทดสอบแสดงให้เห็นว่า ภูมิภาคมีผลต่อ Gender Ratio class อย่างมีนัยสำคัญทางสถิติ กล่าวคือ ค่าเฉลี่ยของ Gender Ratio class แตกต่างกันระหว่างภูมิภาคต่าง ๆ อย่างน้อยหนึ่งภูมิภาค

d) ผลการทดสอบชี้ให้เห็นว่า Gender Ratio class และ Region ไม่เป็นอิสระต่อกัน กล่าวคือ การกระจายของ Gender Ratio class แตกต่างกันอย่างมีนัยสำคัญระหว่างภูมิภาคต่าง ๆ แสดงว่าภูมิภาคมีความสัมพันธ์กับการจัดกลุ่ม Gender Ratio class

Part 1.2: Feature Extraction

Linear Discriminant Analysis (LDA)

a) ในการลดมิติข้อมูลและวิเคราะห์ความสามารถในการจำแนกกลุ่ม ได้ใช้วิธี Linear Discriminant Analysis (LDA) ซึ่งเป็นเทคนิคการลดมิติข้อมูลแบบมีผู้สอน (supervised dimensionality reduction) โดยอาศัยข้อมูลคลาสของตัวแปรเป้าหมายเพื่อหาทิศทางเชิงเส้นที่สามารถแยกกลุ่มข้อมูลได้ดีที่สุด

b) ในการวิเคราะห์ครั้งนี้ ได้เลือกใช้ 4 discriminant components (LD1-LD4) เพื่อเป็นตัวแทนของข้อมูล เนื่องจากสามารถอธิบายความแปรปรวนระหว่างกลุ่มได้เป็นสัดส่วนสูง และเพียงพอในการแทนโครงสร้างหลักของข้อมูลสำหรับการวิเคราะห์และการสร้างโมเดลต่อไป

c) จากค่าน้ำหนักของตัวแปรในแต่ละ discriminant พบว่า:

LD1-LD3 ได้รับอิทธิพลสูงจากตัวแปรด้าน โครงสร้างประชากรตามช่วงอายุ ได้แก่ สัดส่วนประชากรอายุ 0-14 ปี, 15-64 ปี และ 65 ปีขึ้นไป ซึ่งแสดงให้เห็นว่าความแตกต่างของโครงสร้างประชากรเป็นปัจจัยสำคัญในการแยกกลุ่มข้อมูล

ตัวแปรด้าน อายุคาดเฉลี่ย (Life expectancy) ทั้งเพศชายและเพศหญิง มีบทบาทร่วมในหลาย discriminants สะท้อนถึงความสัมพันธ์ระหว่างคุณภาพชีวิตและการจำแนกกลุ่ม

LD4 ได้รับอิทธิพลจากตัวแปรด้านเศรษฐกิจและแรงงาน เช่น มูลค่าการส่งออก การนำเข้า และขนาดกำลังแรงงาน แสดงถึงบทบาทของปัจจัยทางเศรษฐกิจในการแยกกลุ่มข้อมูล

Principal Component Analysis (PCA)

a) ในการลดมิติข้อมูล ได้ใช้วิธี Principal Component Analysis (PCA) ซึ่งเป็นเทคนิคการลดมิติข้อมูลแบบไม่มีผู้สอน (unsupervised learning) โดยทำการปรับสเกลข้อมูลก่อน และเลือกจำนวนองค์ประกอบหลักจากสัดส่วนความแปรปรวนสะสมของข้อมูล

b) จากการพิจารณาความแปรปรวนสะสม พบว่าต้องใช้ 29 principal components เพื่ออธิบายความแปรปรวนของข้อมูลได้อย่างน้อย 85% ของข้อมูลทั้งหมด อย่างไรก็ตาม ในการตีความเชิงความหมาย จะพิจารณาเฉพาะองค์ประกอบหลักลำดับต้น (PC1–PC4) ซึ่งสะท้อนโครงสร้างสำคัญของข้อมูลได้ชัดเจน

c) ตัวอย่าง PC

PC1 สัมพันธ์กับตัวแปรด้าน โครงสร้างประชากรและคุณภาพชีวิต เช่น สัดส่วนประชากรอายุน้อย อัตราการเกิด อายุคาดเฉลี่ย อัตราการเสียชีวิต และโครงสร้างแรงงานที่เปราะบาง แสดงถึงมิติด้านประชากรและสุขภาพโดยรวมของประเทศ

PC2 สะท้อนมิติด้าน ขนาดและกิจกรรมทางเศรษฐกิจ โดยมีความสัมพันธ์สูงกับ GNI, GDP, ขนาดประชากร กำลังแรงงาน การค้า และการคมนาคมทางอากาศ แสดงถึงระดับกิจกรรมทางเศรษฐกิจและศักยภาพของประเทศ

PC3 เชื่อมโยงกับ โครงสร้างแรงงานหญิงและโครงสร้างประชากรสูงอายุ รวมถึงปัจจัยด้านสุขภาพและลักษณะเชิงภูมิภาคบางส่วน แสดงถึงความแตกต่างด้านโครงสร้างสังคมและบทบาทของแรงงานหญิง

Part 2.0: EDA

ในส่วนของการสำรวจข้อมูลเบื้องต้น (Exploratory Data Analysis: EDA) สำหรับ Part 2.0 ได้ดำเนินการโดยใช้ชุดข้อมูลเดียวกับส่วนก่อนหน้า แต่ขยายข้อมูลในมิติเวลาให้ครอบคลุมระยะเวลา 5 ปี โดยในขั้นตอนนี้ ยังไม่ได้ดำเนินการจัดการค่าที่หายไป (missing values) เพื่อให้สามารถสังเกตลักษณะและข้อจำกัดของข้อมูลดิบได้อย่างครบถ้วน

เริ่มต้นจากการตรวจสอบโครงสร้างและขนาดของชุดข้อมูล รวมถึงการจำแนกชนิดของตัวแปรออกเป็นตัวแปรเชิงตัวเลขและตัวแปรเชิงกลุ่ม โดยกำหนด GNI per capita, PPP (current international \$) เป็นตัวแปรเป้าหมายเชิงตัวเลขที่ใช้ในการวิเคราะห์ จากนั้นได้ทำการสำรวจการกระจายของตัวแปรเชิงตัวเลขด้วยกราฟฮิสโตแกรมและบ็อกซ์พล็อต เพื่อประเมินรูปแบบการกระจาย แนวโน้ม และค่าผิดปกติของข้อมูล

เพื่อศึกษาความสัมพันธ์ระหว่างตัวแปรอิสระกับตัวแปรเป้าหมาย ได้ทำการคำนวณค่าสหสัมพันธ์ (correlation) ระหว่าง GNI per capita และตัวแปรเชิงตัวเลขอื่น ๆ รวมถึงพิจารณาภาพรวมของความสัมพันธ์ผ่านตารางและแผนภาพสหสัมพันธ์ (correlation matrix) ซึ่งช่วยให้เห็นทิศทางและความแรงของความสัมพันธ์ระหว่างตัวแปรในระดับภาพรวม

สำหรับตัวแปรเชิงกลุ่ม ได้ทำการวิเคราะห์ด้วยสถิติเชิงพรรณนา โดยพิจารณาค่าเฉลี่ย ค่ามัธยฐาน และการกระจายของค่า GNI per capita ในแต่ละกลุ่ม พร้อมทั้งใช้กราฟแท่งและบ็อกซ์พล็อตเพื่อเปรียบเทียบความแตกต่างระหว่างกลุ่มข้อมูล วิธีการนี้ช่วยให้เข้าใจว่าปัจจัยเชิงกลุ่ม เช่น ภูมิภาค มีความเกี่ยวข้องกับระดับรายได้ต่อหัวของประเทศในภาพรวมอย่างไร

Part 2.1: Clustering

a) ในการจัดกลุ่มประเทศ (Clustering) งานวิจัยนี้เลือกใช้วิธี K-means clustering โดยพิจารณาเฉพาะตัวแปรเชิงตัวเลข GNI per capita, PPP (current international \$) เพื่อจัดกลุ่มประเทศตามระดับรายได้เฉลี่ยต่อหัวในเชิงกำลังซื้อ

ก่อนทำการจัดกลุ่ม ได้ใช้ Elbow Method เพื่อช่วยกำหนดจำนวนคลัสเตอร์ที่เหมาะสม โดยพิจารณาค่าความเฉื่อย (Inertia) เทียบกับจำนวนคลัสเตอร์ k พบว่าค่า Inertia ลดลงอย่างชัดเจนจนถึง $k = 2$ และเริ่มลดลงในอัตราที่ช้าลงหลังจากนั้น จึงเลือกใช้จำนวนคลัสเตอร์เท่ากับ 2 กลุ่ม

แบบจำลอง K-means ถูกฝึกด้วยพารามิเตอร์ $n_clusters = 2$, $n_init = 10$ และ $random_state = 23$ เพื่อให้ผลลัพธ์มีเสถียรภาพ

ประสิทธิภาพของการจัดกลุ่มถูกประเมินด้วยดัชนีหลายตัว ได้แก่

Silhouette Index = 0.703

แสดงให้เห็นว่าการแยกกลุ่มมีความชัดเจน และข้อมูลภายในคลัสเตอร์มีความคล้ายคลึงกันสูง

Davies–Bouldin Index = 0.461

มีค่าค่อนข้างต่ำ บ่งชี้ว่าคลัสเตอร์มีความแตกต่างกันดีและมีการทับซ้อนต่ำ

Dunn Index = 0.873

แสดงถึงอัตราส่วนระหว่างความห่างของคลัสเตอร์และความกระจายภายในคลัสเตอร์ที่เหมาะสม

Calinski–Harabasz Index = 3149.23

มีค่าสูง สะท้อนถึงโครงสร้างของคลัสเตอร์ที่มีคุณภาพดี

b) จากการใช้ Elbow Method ร่วมกับผลการประเมินประสิทธิภาพด้วยดัชนีต่าง ๆ จึงสรุปว่า จำนวนคลัสเตอร์ที่เหมาะสมคือ 2 คลัสเตอร์ ซึ่งสามารถแยกประเทศออกเป็นกลุ่มรายได้ต่ำถึงปานกลาง และกลุ่มรายได้สูงได้อย่างชัดเจน

c) Cluster 0: ประเทศรายได้ต่ำถึงปานกลาง

จำนวนประเทศ: 773 ประเทศ

ค่าเฉลี่ย GNI per capita: ประมาณ 10,705 ดอลลาร์สหรัฐ

ช่วงค่า GNI per capita: 780 – 26,730 ดอลลาร์สหรัฐ

มีความแปรปรวนภายในกลุ่มค่อนข้างต่ำกว่าอีกคลัสเตอร์

โดยทั่วไปเป็นประเทศกำลังพัฒนา หรือประเทศที่มีโครงสร้างเศรษฐกิจยังไม่พึ่งพาเทคโนโลยีและทุนชั้นสูงมากนัก

Cluster 1: ประเทศรายได้สูง

จำนวนประเทศ: 243 ประเทศ

ค่าเฉลี่ย GNI per capita: ประมาณ 43,310 ดอลลาร์สหรัฐ

ช่วงค่า GNI per capita: 27,240 – 64,600 ดอลลาร์สหรัฐ

มีค่าเฉลี่ยและค่ามัธยฐานสูงอย่างชัดเจน

มักเป็นประเทศพัฒนาแล้ว มีเศรษฐกิจขนาดใหญ่หรือมีผลิตภาพแรงงานสูง

ประเทศภายในคลัสเตอร์เดียวกันมีลักษณะร่วมกันคือระดับรายได้ต่อหัวที่ใกล้เคียงกัน ขณะที่ความแตกต่าง

ระหว่างคลัสเตอร์สะท้อนให้เห็นถึงช่องว่างทางเศรษฐกิจอย่างชัดเจน โดยคลัสเตอร์รายได้สูงมีค่า GNI per capita

สูงกว่าคลัสเตอร์รายได้ต่ำถึงปานกลางหลายเท่าตัว และมีการกระจายของข้อมูลที่แตกต่างกันอย่างมีนัยสำคัญ

Part 2.2: Modeling2

1) Data Science Workflow

Workflow 1:

ในขั้นตอนที่หนึ่ง ได้ทำการแบ่งชุดข้อมูลออกเป็นชุดฝึก (training set) และชุดทดสอบ (test set) โดยใช้สัดส่วน 80/20 เช่นเดียวกับขั้นตอนการสร้างแบบจำลองใน Modeling 1 แต่เปลี่ยนตัวแปรเป้าหมายเป็น GNI per capita, PPP (current international \$) ทั้งนี้ ได้ทำการตัดข้อมูลแถวที่ตัวแปรเป้าหมายมีค่าหายไปออกก่อนการแบ่งข้อมูล เพื่อหลีกเลี่ยงอคติในการฝึกแบบจำลอง

Preprocessing:

สำหรับขั้นตอนการเตรียมข้อมูล (Preprocessing) ได้กำหนดเกณฑ์การจัดการค่าที่หายไป โดยหากตัวแปรใดมีสัดส่วนของข้อมูลที่หายไปมากกว่าร้อยละ 40 จะถูกตัดออกจากการวิเคราะห์ เนื่องจากการเติมค่าแทนในกรณีที่ข้อมูลหายไปจำนวนมากอาจทำให้ข้อมูลบิดเบือน ส่วนตัวแปรที่มีข้อมูลหายไปไม่เกินเกณฑ์ดังกล่าว จะทำการเติมค่าแทนโดยใช้ ค่ามัธยฐาน (median) สำหรับตัวแปรเชิงตัวเลข และ ค่าฐานนิยม (mode) สำหรับตัวแปรเชิงกลุ่ม ซึ่งคำนวณจากชุดฝึกเท่านั้น เพื่อป้องกันข้อมูลรั่วไหล (data leakage)

จากนั้น ได้ทำการจัดการปัญหาความเบ้ของข้อมูล (skewness) โดยหากตัวแปรเชิงตัวเลขใดมีค่า skewness มากกว่าร้อยละ 75 จะใช้การแปลงข้อมูลด้วยวิธี Yeo-Johnson transformation เพื่อปรับการกระจายของข้อมูลให้ใกล้เคียงการแจกแจงปกติ เนื่องจากแบบจำลอง Linear Regression มีความไวต่อข้อมูลที่มีการกระจายไม่สมมาตร

สุดท้าย ได้แปลงตัวแปรเชิงกลุ่มทั้งหมดให้อยู่ในรูปเชิงตัวเลขด้วยวิธี One-Hot Encoding เพื่อให้สามารถนำข้อมูลเข้าสู่แบบจำลองการเรียนรู้ของเครื่องได้อย่างเหมาะสม

Feature Selection:

ในขั้นตอนการคัดเลือกตัวแปร (Feature Selection) ได้ดำเนินการเป็นลำดับขั้นเพื่อเพิ่มประสิทธิภาพและความเหมาะสมของแบบจำลองเชิงเส้น

ขั้นแรก ได้ใช้วิธี Low Variance Filtering โดยกำหนดค่า threshold เท่ากับ 0 เพื่อคัดกรองและตัดตัวแปรที่มีค่าคงที่ออกจากการวิเคราะห์ เนื่องจากตัวแปรดังกล่าวไม่ก่อให้เกิดประโยชน์ในการอธิบายความแปรปรวนของตัวแปรเป้าหมาย

ขั้นต่อมา ได้ใช้ High Correlation Filtering โดยกำหนดเกณฑ์ค่าสหสัมพันธ์ที่ 0.8 เพื่อคัดเลือกและตัดตัวแปรที่มีความสัมพันธ์กันสูงออก เพื่อลดปัญหา multicollinearity ซึ่งส่งผลกระทบต่อเสถียรภาพและความสามารถในการตีความของแบบจำลอง Linear Regression

หลังจากนั้น ได้ประยุกต์ใช้วิธี Recursive Feature Elimination (RFE) โดยทำการวนทดสอบจำนวนตัวแปรที่แตกต่างกัน และประเมินประสิทธิภาพของแบบจำลองจากค่า R^2 และ Mean Absolute Percentage Error (MAPE) เพื่อเลือกจำนวนตัวแปรที่ให้ค่า R^2 สูงและค่า MAPE ต่ำที่สุด ซึ่งถือเป็นชุดตัวแปรที่เหมาะสมที่สุดสำหรับการสร้างแบบจำลองขั้นสุดท้าย

Modeling:

จากขั้นตอนการคัดเลือกตัวแปรด้วยวิธี Recursive Feature Elimination (RFE) ได้เลือกชุดตัวแปรจำนวน 90 ตัวแปร ซึ่งให้ค่า R^2 สูง และค่า MAPE ต่ำ ที่สุด นำตัวแปรที่เหลือไปจัดการ outlier จากนั้นนำตัวแปรดังกล่าวไปสร้างแบบจำลองด้วยวิธี Linear Regression แบบพื้นฐาน (LinearRegression) เพื่อศึกษาความสัมพันธ์เชิงเส้นระหว่างตัวแปรอิสระกับตัวแปรเป้าหมาย GNI per capita, PPP (current international \$)

Performance evaluation:

ประสิทธิภาพของแบบจำลองถูกประเมินด้วยตัวชี้วัดหลายรายการ ได้แก่ RMSE, MAE, MAPE, R^2 และ RMSLE โดยได้ผลลัพธ์ดังนี้

RMSE = 4,709.56

MAE = 2,942.26

MAPE = 28.33%

R^2 = 0.9581

RMSLE = ไม่สามารถคำนวณได้ (NaN)

ค่า R^2 ที่สูง แสดงให้เห็นว่าแบบจำลองสามารถอธิบายความแปรปรวนของ GNI per capita ได้ดี อย่างไรก็ตาม ค่า MAPE ที่ยังอยู่ในระดับค่อนข้างสูง สะท้อนว่าความคลาดเคลื่อนเชิงสัดส่วนยังมีอยู่ โดยเฉพาะในประเทศที่มีค่า GNI ต่ำหรือสูงหรือต่ำมาก นอกจากนี้ ค่า RMSLE ไม่สามารถคำนวณได้ อาจเกิดจากการมีค่าศูนย์หรือค่าลบในข้อมูลจริงหรือค่าที่แบบจำลองทำนาย ซึ่งเป็นข้อจำกัดของตัวชี้วัดนี้

Workflow 2:

ขั้นตอนใน Workflow 2 มีโครงสร้างโดยรวมเหมือนกับ Workflow 1

Preprocessing:

การเตรียมข้อมูลดำเนินการเช่นเดียวกับ Workflow 1 ได้แก่ การจัดการค่าที่หายไปโดยใช้เกณฑ์ร้อยละ 40 และเติมค่าทดแทนด้วย median สำหรับตัวแปรเชิงตัวเลข และ mode สำหรับตัวแปรเชิงกลุ่มจากชุดข้อมูลฝึก (training set) จากนั้นทำการเข้ารหัสตัวแปรเชิงกลุ่มด้วยวิธี One-Hot Encoding อย่างไรก็ตาม ใน Workflow นี้ไม่ได้ทำการปรับแก้ความเบ้ของข้อมูล (skewness)

Feature Selection:

ในขั้นตอนการคัดเลือกตัวแปร เริ่มจากการใช้ Low Variance Filtering ด้วย threshold เท่ากับ 0 เพื่อกำจัดตัวแปรที่มีค่าคงที่ ตามด้วย High Correlation Filtering ที่เกณฑ์ 0.8 เพื่อลดปัญหา multicollinearity หลังจากนั้น ใช้ค่า Feature Importance จาก Random Forest เพื่อจัดอันดับความสำคัญของตัวแปร และทำการคัดเลือกจำนวนตัวแปรที่เหมาะสม โดยพิจารณาจากประสิทธิภาพของแบบจำลองที่ได้จากค่า R^2 และ MAPE เพื่อเลือกชุดตัวแปรที่ให้ผลการทำนายดีที่สุด

Modeling:

หลังจากใช้ค่า Feature Importance จาก Random Forest เพื่อคัดเลือกตัวแปร พบว่าการใช้จำนวน 15 ตัวแปร ให้ค่า R^2 สูง และ MAPE ต่ำที่สุด จึงเลือกใช้ตัวแปรเหล่านี้เป็นอินพุตของแบบจำลองขั้นสุดท้าย ทั้งนี้เลือกใช้ Random Forest Regressor เนื่องจากสามารถจับความสัมพันธ์เชิงไม่เชิงเส้นระหว่างตัวแปรกับ GNI per capita ได้ดี ไม่ไวต่อปัญหา multicollinearity และมีความทนทานต่อ noise ในข้อมูล ส่งผลให้แบบจำลองมีความเสถียร และให้ผลการทำนายที่มีประสิทธิภาพสูง

Performance evaluation:

แบบจำลอง Random Forest Regressor ที่ใช้ตัวแปรคัดเลือกจำนวน 15 ตัวแปร ให้ผลการทำนายที่มีประสิทธิภาพสูง โดยมีค่า $R^2 = 0.967$ แสดงให้เห็นว่าโมเดลสามารถอธิบายความแปรปรวนของค่า *GNI per capita* ได้เป็นสัดส่วนสูง ขณะที่ค่า MAPE = 11.37% และ MAE = 2,100 บ่งชี้ว่าความคลาดเคลื่อนในการทำนายอยู่ในระดับต่ำเมื่อเทียบกับช่วงค่าของตัวแปรเป้าหมาย นอกจากนี้ค่า RMSE = 4,194 และ RMSLE =

0.154 สะท้อนให้เห็นว่าโมเดลมีความแม่นยำและมีความเสถียรในการทำนาย โดยเฉพาะเมื่อพิจารณาข้อผิดพลาดเชิงสัดส่วน เหมาะสมสำหรับการทำงานกับข้อมูลทางเศรษฐกิจที่มีการกระจายตัวสูง

2) Result interpretation

a) แบบจำลองขั้นสุดท้ายใช้ Random Forest Regressor ร่วมกับตัวแปรที่ผ่านการคัดเลือกจำนวน 15 ตัวแปร โดยประเมินประสิทธิภาพด้วยตัวชี้วัดสำหรับปัญหา Regression ดังนี้

RMSE = 4,193.56

MAE = 2,100.17

MAPE = 11.37%

$R^2 = 0.967$

RMSLE = 0.154

ค่า R^2 ที่สูงถึง 0.967 แสดงให้เห็นว่าแบบจำลองสามารถอธิบายความแปรปรวนของค่า *GNI per capita, PPP* ได้เกือบทั้งหมด ขณะที่ค่า MAPE ประมาณ 11% บ่งชี้ว่าความคลาดเคลื่อนเชิงสัดส่วนอยู่ในระดับต่ำเมื่อเทียบกับช่วงค่าของ *GNI per capita* ซึ่งมีความแตกต่างกันสูงระหว่างประเทศ นอกจากนี้ ค่า RMSE และ MAE อยู่ในระดับที่เหมาะสมเมื่อพิจารณาขนาดของตัวแปรเป้าหมาย และค่า RMSLE ที่ต่ำสะท้อนว่าแบบจำลองสามารถจัดการกับข้อมูลที่มีการกระจายแบบเอียงและมีค่าขนาดใหญ่ได้ดี

b) จากการวิเคราะห์ Feature Importance ของ Random Forest พบว่าตัวแปรที่มีอิทธิพลต่อการทำนาย *GNI per capita* อย่างมีนัยสำคัญ ได้แก่

Life expectancy at birth, male (years) เป็นตัวแปรที่มีความสำคัญสูงสุด สะท้อนถึงความเชื่อมโยงระหว่างคุณภาพชีวิต สุขภาพประชากร และระดับรายได้ของประเทศ

Fixed broadband subscriptions และ Secure Internet servers แสดงถึงบทบาทของโครงสร้างพื้นฐานด้านดิจิทัล ซึ่งสัมพันธ์กับระดับการพัฒนาและกิจกรรมทางเศรษฐกิจ

Gross savings (% of GDP) และ Exports of goods and services (% of GDP) สะท้อนศักยภาพทางเศรษฐกิจ ความสามารถในการออม และการเชื่อมโยงกับเศรษฐกิจโลก


ตัวแปรด้านโครงสร้างเศรษฐกิจ เช่น Agriculture, forestry, and fishing value added (% of GDP) และ

Permanent cropland (% of land area) ช่วยอธิบายความแตกต่างเชิงโครงสร้างระหว่างประเทศรายได้ต่ำและรายได้สูง

ในขณะที่ตัวแปรบางส่วน เช่น Net ODA received (% of GNI) และ Vulnerable employment (male) มีความสำคัญต่ำกว่า ซึ่งสอดคล้องกับบทบาทที่เป็นผลตามระดับรายได้มากกว่าปัจจัยกำหนดโดยตรง

Part 2.3: Visualization


a) เพื่อวิเคราะห์และนำเสนอความสัมพันธ์ระหว่างระดับรายได้ของประเทศ (GNI per capita, PPP) กับระดับการเข้าถึงการศึกษา (Primary, Secondary และ Tertiary) โดยเปรียบเทียบในมิติของ ภูมิภาคและช่วงเวลา



b) Regional Share of GNI per Capita (Pie Chart)

เพื่อแสดงสัดส่วนของ GNI per capita ที่รวมกันในแต่ละภูมิภาคเมื่อเทียบกับทั่วโลก


Regional Share of GNI per Capita



Relationship between GNI per Capita and School Enrollment (Primary)

เพื่อศึกษาความสัมพันธ์ระหว่างรายได้ต่อหัวกับอัตราการเข้าเรียนระดับประถมศึกษา


Relationship between GNI per Capita and School Enrollment Primary



Relationship between GNI per Capita and School Enrollment (Secondary)

เพื่อวิเคราะห์ความสัมพันธ์ระหว่างรายได้ต่อหัวกับอัตราการเข้าเรียนระดับมัธยมศึกษา


Relationship between GNI per Capita and School Enrollment Secondary



Relationship between GNI per Capita and School Enrollment (Tertiary)

เพื่อแสดงความสัมพันธ์ระหว่างรายได้ต่อหัวกับอัตราการเข้าเรียนระดับอุดมศึกษา


Relationship between GNI per Capita and School Enrollment Tertiary



Average GNI per Capita over Time by Region (Line Chart)

เพื่อแสดงแนวโน้มการเปลี่ยนแปลงของ GNI per capita เฉลี่ยในแต่ละภูมิภาคตามช่วงเวลา


Average GNI per Capita over Time by Region



Distribution of GNI per Capita (Histogram)

เพื่อแสดงการกระจายตัวของ GNI per capita ในระดับประเทศ

Distribution of GNI per Capita



c) แดชบอร์ดนี้ออกแบบตาม โครงสร้างการเล่าเรื่องจากภาพรวมไปสู่รายละเอียด (Overview > Relationship > Trend > Distribution) ดังนี้:

1. ภาพรวมเชิงโครงสร้างเศรษฐกิจโลก

เริ่มต้นด้วย Pie Chart เพื่อให้ผู้ใช้เข้าใจการกระจายรายได้ในระดับภูมิภาค

2. การวิเคราะห์ความสัมพันธ์เชิงสาเหตุ

ต่อด้วย Scatter Plots ทั้งสามระดับการศึกษา เพื่อเปรียบเทียบว่าความสัมพันธ์ระหว่างรายได้กับการศึกษา

เปลี่ยนไปอย่างไรในแต่ละระดับ

3. มุมมองเชิงเวลา

ใช้ Line Chart เพื่อแสดงแนวโน้มการเปลี่ยนแปลงของรายได้ในระยะยาว

4. การทำความเข้าใจโครงสร้างข้อมูล

ปิดท้ายด้วย Histogram เพื่ออธิบายลักษณะการกระจายของรายได้ ซึ่งช่วยสนับสนุนการตีความกราฟอื่น ๆ